

# **MACHINE LEARNING NA PREVISÃO DE HORAS DE SUBSTITUIÇÃO DE ÓLEO DO MOTOR: FOCO EM IMPACTO AMBIENTAL, CUSTO & PERFORMANCE**

Camila Caroline Rendeiro Gildo <sup>1</sup>

Bruno Nascimento Cuimar <sup>2</sup>

Felipe Vital Cacique <sup>3</sup>

Cid Clay Quirino <sup>4</sup>

Felipe Duarte Pedra <sup>5</sup>

## **Resumo**

Este estudo foi desenvolvido com base em um estudo de caso que aborda a utilização de um modelo de Machine Learning na análise de dados de degradação de óleo do motor, tendo como um dos objetivos, prever o momento ótimo de troca, indicando ou não, uma possível viabilidade de extensão de horas.

Em geral a troca de óleo de motor é definida considerando somente a média de horas operadas definidas pelos fabricantes, sem considerar as reais propriedades dos lubrificantes. Nesse trabalho, os limites especificados de degradação, foram os definidores do intervalo de reposição, sendo possível obter intervalos de troca consideravelmente acima do número de horas especificado pelo fabricante.

Em alguns casos o limite de horas para saturação do óleo pode ser 50% maior do que as horas recomendadas, indicando para a possibilidade de melhora na produtividade dos ativos, redução dos custos de manutenção e nos impactos causados pelas constantes trocas e descarte ao meio ambiente, podendo chegar a valores de aproximadamente/ano 2000 litros de óleo em uma frota de 5 equipamentos.

Adicionalmente, foram obtidas algumas respostas para perguntas pertinentes, tais como: Qual foi o comportamento do óleo durante o tempo de operação quando comparados os níveis de degradação para ambos os motores? Qual a evolução da saúde do óleo até o horário normal de troca? Qual foi o padrão de comportamento dos dados (linear ou exponencial)?

Qual o número de horas projetadas em que ambos os óleos de motor atingiram os limites de degradação, nessa operação, sendo por isso, possível sugerir a alteração de troca para mais do que as atuais 500 horas de operação.

## **1. Introdução**

Na avaliação de Hugo Raposo et al. (2019), muitas vezes, em condições normais de funcionamento, as propriedades dos lubrificantes, com base nos intervalos que recomendam para sua mudança, encontram-se dentro da normalidade e condições de segurança.

Já Jose Guerrero et al. (2015), alerta para o fato de que a degradação do fluido é responsável por inúmeras falhas de equipamentos, sendo um dos mais importantes parâmetros para controlar em uma instalação industrial.

Em especial a degradação do óleo motor deve ser monitorada, considerando a complexidade do componente, e os altos níveis de temperatura de trabalho a que estão submetidas as peças internas. Vladimír Hönig et al. (2020) no estudo sobre a determinação de intervalos de troca de óleo, avalia que os óleos do motor têm um grande efeito no funcionamento adequado do componente. A função mais importante dos óleos é a lubrificação, que deve ser assegurada não apenas em todas as temperaturas de operação, mas também em níveis de carga. Além disso, o resfriamento (transferência de calor produzida durante a combustão ou fricção de movimento das peças), estanqueidade da câmara de combustão, proteção contra corrosão e conservação de superfícies metálicas quando o motor não está funcionando são propriedades necessárias do óleo do motor. Além disso, este óleo deve garantir a remoção adequada de sujeira e redução de ruído.

Os riscos e os benefícios podem ter mensuração difícil ao iniciar um programa de extensão do intervalo de troca de óleo em motores que trabalham com severidade alta. O que justifica a necessidade de uma base de informação consistente para correlacionar a interpretação dos dados do laboratório de análise de óleo e a projeção desse comportamento com base em uma análise consistente para definir a periodicidade de intervalo de troca de óleo.

## 2. Análise de óleo lubrificante

Para o desenvolvimento do projeto, alguns fatores importantes referentes ao cliente foram observados:

- Erros de manutenção e práticas incorretas nas rotinas de manutenção preventiva afetam o estado do óleo, resultando em aceleração e acentuação do desgaste nas partes móveis do motor. É por isso que o Cobre (Cu) e o Ferro (Fe) foram examinados de perto durante as avaliações;
- A severidade da operação é extrema no processo de mineração. Nas operações de bauxita no norte do Brasil, os tratores de esteiras modelo D11 são os equipamentos utilizados na produção do mineral, nesta atividade superam os 70% do fator de carga, algo incomum para um equipamento dessa categoria. Além disso, a natureza da operação leva a um número significativo de ciclos por dia o que requer atenção especial ao comportamento do óleo.

Como acontece na maioria das decisões de negócios, estender o intervalo de troca de óleo pode representar riscos e recompensas. O maior benefício potencial é o ganho na disponibilidade devido a menor quantidade das paradas para lubrificação. Caso contrário, esta vantagem pode ser rapidamente desqualificada se a vida útil do componente for reduzida devido ao desgaste prematuro.

Os parâmetros selecionados para garantir que não haja danos ao motor foram baseados nos seguintes fatores:

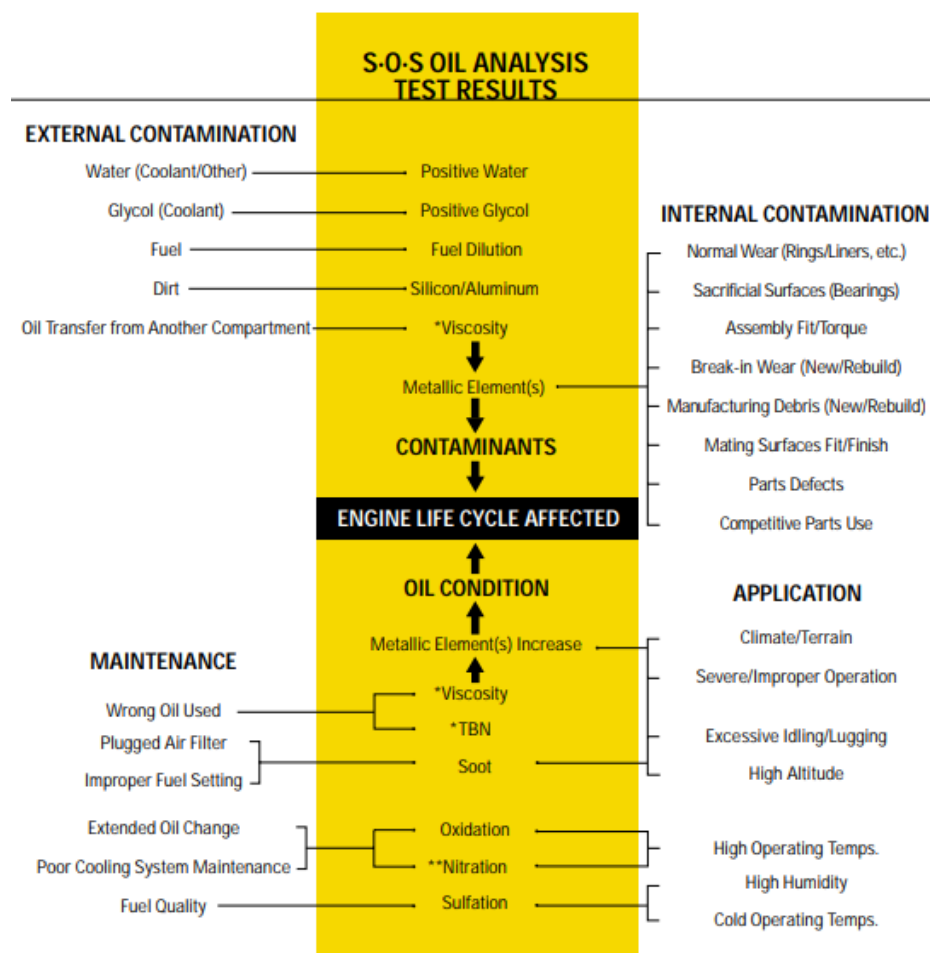
- **Viscosidade a 100 ° C (V100):** Condição que permite uma camada/filme de lubrificante para todas as partes móveis. A viscosidade é indiscutivelmente a característica mais importante de óleo lubrificante e tende a relacionar-se com níveis de contaminantes, oxidação e número de ácido (AN; Van Rensselaar 2012)
- **TBN (Número Base Total):** Mede a capacidade do óleo de neutralizar os ácidos gerados na combustão.
- **Oxidação:** Mostra a degradação do óleo, diretamente afetada pelas horas de troca de óleo. Parâmetro principal na investigação do ponto ideal de troca de óleo.
- **Fuligem:** Representa a qualidade da combustão, afetada pela taxa de fornecimento de ar ou combustível, mantendo suas capacidades detergentes.

- **Sulfatação:** Mostra o impacto do traço do diesel no óleo, comumente afetado pela má qualidade do diesel.
- **Nitração:** Impacto do mau estado do sistema de refrigeração. Também afetado pela oxidação.

A Figura 1, e o fabricante de equipamentos Caterpillar, em seu artigo “Optimizing Oil Change Intervals”, ilustram alguns dos principais parâmetros de observação quanto a mensuração do desempenho do óleo do motor:

- A correta aplicação do equipamento;
- A utilização de filtros de óleo e de ar de qualidade;
- Adequada manutenção no sistema de arrefecimento;
- Boas práticas de operação;
- Controle do nível de contaminação externa.

FIGURA 1: Compreendendo as causas do desgaste do motor



Caterpillar: PEDP7035

Segundo o que é recomendado pelo fabricante de máquinas Caterpillar, e apresentado na Figura 2 logo a seguir, o balanço correto de intervalos de troca de óleo, é uma decisão de negócio, e tal como acontece com a maioria das decisões de negócios, estabelecer um intervalo de troca de óleo do motor além da recomendação do fabricante implica em equilibrar riscos e recompensas.

*FIGURA 2: O equilíbrio do intervalo de troca de óleo*



*Fonte: Caterpillar PEHJ0192-01 [www.cat.com](http://www.cat.com)*

Provavelmente a maior vantagem é o aumento da disponibilidade devido ao menor tempo de inatividade para manutenção. Mas este acréscimo na disponibilidade pode ser rapidamente corroído se a troca prolongada de óleo estiver causando desgaste prematuro e tempo maior de inatividade para reparos.

## **2.1. MACHINE LEARNING: Support Vector Machine (SVM/SVR)**

Para Jan Luts (2010), no campo de aprendizado de máquina e reconhecimento de padrões, pesquisadores desenvolvem métodos e programas de computador para realizar uma certa tarefa. Neste contexto, certos métodos de aprendizagem tentam otimizar um critério de desempenho usando dados de exemplo ou experiência anterior.

Em caso de aprendizagem supervisionada os métodos de aprendizagem são adotados com base nestes exemplos (ou seja, a chamada aprendizagem ou fase de treinamento), que incluem valores de saída. Uma vez que o parâmetro de um

classificador é obtido a partir desses dados de exemplo, eles geralmente são chamados de dados de treinamento.

Jan Luts (2010), explica que embora SVMs (Support Vector Machine) possuam quase 50 anos de existência, um grande avanço foi realizado durante o início dos anos noventa. Originalmente, o método se tornou popular nas redes neurais e comunidade de aprendizado de máquina, e depois foi aceito em muitos outros campos.

É possível pensar nos algoritmos de aprendizado de máquina como um arsenal repleto de ferramentas, mas deve-se aprender a usá-las no momento certo. Zhibin Li et al. investigou a possibilidade de usar modelos de SVM para análise da gravidade das lesões por acidente, verificou-se que a modelagem por SVM produziu melhor desempenho de previsão para lesões por acidente e severidade do que o modelo estatístico OP.

Os modelos SVMs são bem conhecidos para problemas de classificação, sendo que no uso de SVMs, para o presente estudo foram feitas avaliações utilizando um subgrupo do SVM para regressão, os denominados algoritmos conhecidos como Support Vector Regression (SVR).

Neste artigo, os resultados de projeção dos parâmetros de saúde dos óleos lubrificantes foram feitos e comparados entre o SVR e a Regressão Linear. O objetivo foi identificar qual modelo de projeção seria mais aderente em projetar os parâmetros de saúde até os limites especificados pelo Fabricante dos Óleos.

Na Figura 3, são apresentados os limites especificados para cada um dos parâmetros estudados, os resultados indicaram uma linearidade no comportamento dos dados, conforme pode ser visto na Figura 5.

*FIGURA 3: Setup dos limites par aos principais parâmetros*

```
thresholds = {  
    'TBN': {'max': None, 'min': 7.00},    #ok  
    'OXI': {'max': 24.00, 'min': None},  #ok  
    'V100': {'max': 15.00, 'min': 9.00}, #ok  
    'ST': {'max': 60.00, 'min': None},  
    'NIT': {'max': None, 'min': None},  
    'SUL': {'max': 28.00, 'min': None},  #ok  
    'CU': {'max': 10.00, 'min': None},  
    'FE': {'max': 36.00, 'min': None}  
}
```

*Fonte: Caterpillar Oil Limit*

A avaliação do ajuste aos modelos, entre os modelos lineares e polinomiais, elaborando a análise por meio da comparação entre o Erro Médio Absoluto (MAE) como parâmetro de aderência ao modelo.

Laura Frias (2018) indica para a existência de muitos índices estatísticos para medir a diferença entre duas séries temporais que são usadas por cientistas e engenheiros para avaliar a qualidade dos métodos de previsão, incluindo o erro médio absoluto (MAE). Laura Frias (2018) explica que a análise de erros de predição é um ponto crítico de um estudo envolvendo dados temporais, e permite uma comparação entre modelos de previsão e a seleção do modelo mais adequado.

Ou seja, o SVR é um algoritmo poderoso, contudo deve ser estudado e comparado a outros métodos, com o objetivo de entender qual modelo melhor se adequa ao comportamento dos dados.

Na Figura 4, é apresentada a biblioteca utilizada como parte da linguagem de programação Python, para a avaliação dos dados do óleo lubrificante coletados em ambos os Motores.

*FIGURA 4: SVM/SVR e MAE seleção de algoritmo de análise (Python)*

```
from sklearn.svm import SVR
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import cross_val_score
from sklearn.metrics import mean_absolute_error, r2_score

my_model = SVR(kernel='linear')
|
cv = len(X['Horas Oleo'])
scores = -1 * cross_val_score(my_model,X,y,cv=cv,scoring='neg_mean_absolute_error')
print("MAE from cross valid: ", scores.mean())
```

*Fonte: Python/Jupyter Notebook (Próprio Autor)*

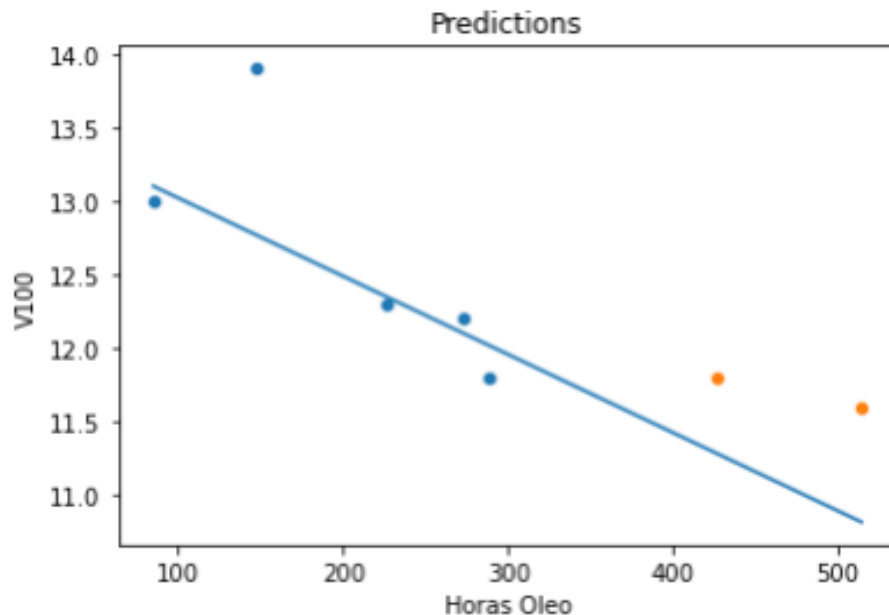
Na Figura 5, é apresentada a projeção por SVR para o parâmetro V100 com 7 amostras totais, sendo 5 delas utilizadas como treinamento para o modelo.

Para esse exemplo, a amostra foi reduzida a uma carga de óleo a fim de explicar a forma de utilização dos dados de treinamento e dados de projeção.

FIGURA 5: Projeção por SVR

```
pred_all = my_model.predict(X)

figure = plt.figure()
sns.scatterplot(x=X_train['Horas Oleo'], y=y_train, legend='full')
sns.scatterplot(x=X_valid['Horas Oleo'], y=y_valid, legend='full')
sns.lineplot(x=X['Horas Oleo'], y=pred_all)
plt.title("Predictions")
```



Fonte: Próprio autor

### 3. Metodologia

#### 3.1. Análise das propriedades do óleo em intervalos reduzidos


As etapas básicas de implementação para a avaliação foram:

- Definição de duas máquinas, etiquetadas TE8037 e TE8038;
- Coleta de amostras duas (02) vezes por semana a cada 50 horas;
- Após processo de coleta dos dados referentes as cargas, uma análise de tendência foi conduzida para identificar a condição de cada carga de óleo durante as 500 horas do intervalo de troca;
- Em seguida, é realizada a elaboração das curvas de tendência e aplicação de análise com Machine Learning, esta análise foi utilizada para concluir se os parâmetros de ambos os motores, superaram ou não a expectativa




de 500 horas, mostrando a oportunidade de extensão do intervalo. Esses resultados podem ser vistos nos gráficos a seguir;

No Gráfico 1, é apresentado o comportamento dos dados de Sulfatação (SUL) para o ativo TE 8038, e para o ativo TE 8037 apresentado no Gráfico 2. A projeção para ambos os lubrificantes, atingem o limite especificado com 1058 e 1226 horas de operação.




*Fonte: Próprio Autor*




*Fonte: Próprio Autor*

Nos Gráficos 3 e 4, é possível observar que ambos os equipamentos TE 8038 e TE 8037, superaram as 1000 horas de operação.



*Fonte: Próprio Autor*




*Fonte: Próprio Autor*

Nos Gráficos 5 e 6, constam os resultados do comportamento da Viscosidade a 100°C (V100) para ambos os equipamentos TE 8038 e TE 8037. Na projeção para ambos os ativos, o parâmetro V100 superará as expectativas de operação com


respectivamente 1436 horas e 1557 horas de operação. Sendo importante observar, que esse é um dos parâmetros mais importantes para a manutenção da qualidade do lubrificante, quando submetido a trabalhos extremos, tais como os indicados nesse artigo.

GRÁFICO 5: Projeção do V100 TE-8038



Fonte: Próprio Autor


GRÁFICO 6: Projeção do V100 TE-8037



Fonte: Próprio Autor


No Gráfico 7, é apresentado o resultado do comportamento do Basicidade Total (TBN) para o TE 8038, e para o TE 8037 no Gráfico 8. Na projeção para o TBN, o modelo linear estimou aproximadamente 730 horas até a manutenção dos limites especificados, TE8037, a projeção estabilizou-se em 1311 horas até atingir os limites especificados.

GRÁFICO 7: Projeção do TBN TE-8038



Fonte: Próprio Autor


GRÁFICO 8: Projeção do TBN TE-8037



Fonte: Próprio Autor


Nos Gráficos 9 e 10, é apresentado o resultado do comportamento do Fuligem (ST) para o TE 8038 e para o TE 8037. A projeção para o ST não considera o limite, pois este parâmetro não possui um limite especificado.

GRÁFICO 9: Projeção do ST TE-8038



Fonte: Próprio Autor

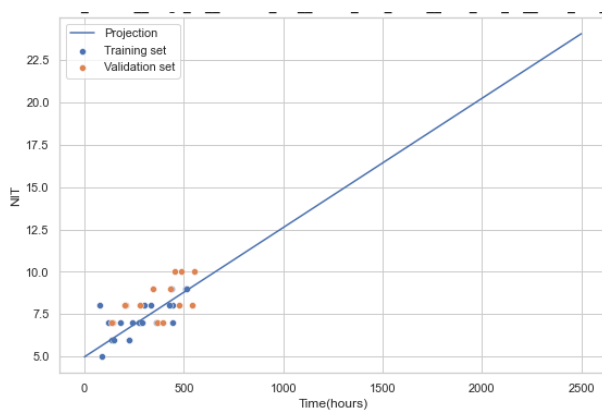
GRÁFICO 10: Projeção do ST TE-8037



Fonte: Próprio Autor


No Gráfico 11, é apresentado o resultado do comportamento do Nitração (NIT) para o TE 8038, e para o TE 8037 no Gráfico 12. A projeção para o NIT de ambos os óleos não consideram o limite, pois este parâmetro não possui um limite especificado.

GRÁFICO 11: Projeção do NIT TE-8038



Fonte: Próprio Autor

GRÁFICO 12: Projeção do NIT TE-8037





Fonte: Próprio Autor

No Gráfico 13, é apresentado o resultado do comportamento do Basicidade Total (TBN) para o TE 8038 e para o TE 8037, no Gráfico 14. Na projeção pelo modelo Polinomial, que para este caso, teve Erro Médio Absoluto (MAE) como sendo o mais

alto dentre os modelos, tendo como resultado projetado 578hs para o óleo do TE 8038 e 688hs para o TE 8037.

As projeções com o modelo polinomial, não se mostraram aderente aos dados, por isso definiu-se por demonstrar as projeções para os modelos lineares e mais aderentes aos dados de projeção de óleo motor.



A Tabela 1 abaixo apresenta a comparação entre 3 modelos de algoritmo. Os resultados da primeira e da terceira colunas, são análises que utilizaram modelos com base linear, a segunda coluna contém resultados do modelo SVM como base polinomial. Os modelos que utilizam a linearização se mostraram mais aderentes, em comparação com polinomial.

Os pontos em negrito são os melhores resultados do parâmetro Erro Médio Absoluto (MAE), nesse caso para o motor do TE 8037.

TABELA 1: Comparação entre os parâmetros Regressão Linear a SVM par ao motor do te 8037

The validation MAE for the motor TE8037 with carga 32 and trained using 20 points and validated using 14 points is:			
Compound	svm_linear	svm_poly	linear_reg
TBN	<b>0,297</b>	0,368	0,305
OXI	<b>1,693</b>	1,832	1,863
V100	0,494	<b>0,478</b>	0,481
ST	1,349	1,880	<b>1,209</b>
NIT	2,500	2,400	<b>2,378</b>
SUL	2,273	2,320	<b>2,218</b>
CU	2,821	<b>2,531</b>	3,790
FE	5,619	5,404	<b>4,478</b>

Fonte: Próprio Autor

Os resultados da Tabela 2, também indicam para os modelos lineares como sendo modelo mais aderente, a partir do Erro Médio Absoluto (MAE) para os casos estudados no motor do TE 8038. O modelo Polinomial conseguiu erros menores em apenas um caso, que foi o de NIT.

*TABELA 2: Comparação entre os parâmetros Regressão Linear a SVM para motor do TE 8038*

The validation MAE for the motor TE8038 with carga 32 and trained using 20 points and validated using 14 points is:			
Compound	svm_linear	svm_poly	linear_reg
TBN	0,258	0,365	<b>0,249</b>
OXI	1,679	1,731	<b>1,587</b>
V100	0,338	0,398	<b>0,338</b>
ST	1,920	1,794	<b>1,520</b>
NIT	1,073	<b>0,945</b>	0,988
SUL	<b>4,107</b>	4,127	4,222
CU	<b>2,278</b>	2,284	4,817
FE	<b>5,926</b>	5,970	6,037

*Fonte: Próprio Autor*

#### 4. Conclusões

Estender o intervalo de troca de óleo é uma das alternativas para economizar recursos financeiros e reduzir custos operacionais em ambientes e condições em que as máquinas moveis são os principais ativos. Ao mesmo tempo, é importante entender e controlar os riscos de danos ao motor com intervalo de troca mais longo, quando feito sem fundamentação técnica.

Os riscos e benefícios devem ser compreendidos e compartilhados entre o Fabricante/Revendedor e Cliente antes do início de um projeto como este. Usar um robusto algoritmo de aprendizado de máquina para análise de tendência dos parâmetros como ferramenta de apoio a decisão, possibilita maior assertividade em procedimentos relativos à extensão da vida útil do óleo.

Como os principais ganhos tangíveis do adiamento das trocas de óleo, podemos listar maior tempo de operação, o que significa maior MTBS (tempo médio entre paradas), menores custos de manutenção e menos óleo lubrificante e filtros para serem descartados. Para isso, o uso de um protocolo claro e técnico é necessário

para garantir que estas vantagens são sustentáveis e não serão neutralizadas por paradas inesperadas, componentes com vida útil encurtada ou falha catastrófica do motor. Além disto, é necessário continuar vistoriando o óleo usando a análise laboratorial.

Especificamente neste projeto, foi demonstrado potencial para adicionar 50% mais horas de operação entre óleo e mudanças de filtro de óleo, representando 48 kg de descarte de filtro e 532 L a menos de óleo descarregado por cada uma das máquinas anualmente, além de uma economia de R\$ 0,48 por hora.

Pode-se ainda, atestar a precisão dos modelos de Machine Learning e algoritmos baseados em SVMs linear, usando o Erro Médio Absoluto como parâmetro em comparação a métodos. A aderência dos modelos de degradação dos parâmetros de óleo, indicam que até as 500hs de dados reais, os dados se comportam de forma linear, contudo, outros modelos devem ser testados para garantir que tal resultado possa ser efetivamente comprovado.

A utilização de análises de Machine Learning para avaliar esse tipo de comportamento, demonstra que estes artifícios computacionais são plenamente capazes de fornecer subsídios para a tomada de decisões importantes, no contexto de negócios envolvendo estratégias de gerenciamento, substituição e monitoramento de degradação dos óleos de motor, mitigando prejuízos a operação, otimizando a performance de frota e minimizando consequências ambientais.

## REFERÊNCIAS

Hugo Raposo et al. (2019) '**Condition Monitoring with Prediction Based on Diesel Engine Oil Analysis: A Case Study for Urban Buses**', **Actuators**, 8(1), p. 14. DOI: 10.3390/act8010014.

Guerrero, Jose et al. (2015) **Fluid Degradation Measurement Based on a Dual Coil Frequency Response Analysis**, **Sensors**, 2020, Vol.20(15), p.4155, E-ISSN: 14248220; DOI: 10.3390/s20154155.

Hönig, V. et al. (2020) '**Determination of Tractor Engine Oil Change Interval Based on Material Properties**', **Materials** (Basel, Switzerland), 13(23). DOI: 10.3390/ma13235403.

Caterpillar **Optimizing Oil Change Intervals**, PEDP7035, acessado em 08/08/21 at [www.CAT.com](http://www.CAT.com).

Caterpillar **Optimizing Oil Change Intervals**, For Cat® Diesel Engines, PEHJ0192-01, acessado em 08/08/21 at [www.cat.com](http://www.cat.com).

Luts, Jan et al. **A tutorial on support vector machine-based methods for classification problems in chemometrics**, *Analytica chimica acta*, 2010, Vol.665(2), pp.129-145. ISSN: 0003-2670; E-ISSN: 1873-4324; DOI: 10.1016/j.aca.2010.03.030

Frías-Paredes, Laura; Mallor, Fermin; Gastón-Romeo, Martín; León, Teresa. **Dynamic mean absolute error as new measure for assessing forecasting erros**. *Energy conversion and management*, 15 April 2018, Vol.162, pp.176-188, ISSN: 0196-8904; E-ISSN: 1879-2227; DOI: 10.1016/j.enconman.2018.02.030